Universidad Técnica Estatal de Quevedo

Facultad: por confirmar
Carrera: Ingeniería de Software
Aplicaciones Distribuidas

Entrega y recuperación de mensajes en Discord

Comparación con Zulip

TA-IND-01
Borrador de trabajo

Byron Daniel Loor Mendoza
Paralelo: por confirmar
Fecha de entrega: por confirmar

Repositorio del informe

Resumen

Este informe analiza la entrega y el almacenamiento de mensajes de texto en Discord y los compara con Zulip, una plataforma de chat para equipos. La comparación se apoya en la documentación técnica de ambos sistemas y considera la arquitectura, los protocolos, las transparencias, la consistencia, la latencia y la recuperación ante fallos. Se realizó una prueba con un navegador en una laptop y la aplicación de Discord en un teléfono conectado por datos móviles. Durante el corte de la laptop se enviaron tres mensajes desde el teléfono. Al reconectar, los tres aparecieron en Chrome en el mismo orden, sin duplicados visibles ni recarga manual. La prueba permitió observar la recuperación del estado visible del cliente. La documentación de almacenamiento y el incidente de autenticación de Discord permiten examinar, por separado, cómo la carga, la replicación y los fallos afectan al servicio. En Zulip, el análisis distingue el historial persistente en PostgreSQL de la cola que entrega eventos. El resultado de la prueba tiene alcance local y el análisis de garantías internas depende de la operación y de la configuración documentadas.

1. Introducción

La pregunta del informe es qué compromisos entre latencia, consistencia y recuperación ante fallos se observan en la entrega y el almacenamiento de mensajes de texto en Discord, y cómo se comparan con los de Zulip. Los canales permiten que comunidades conversen en tiempo real y que quienes se conectan después consulten lo publicado. Esto requiere resolver dos problemas relacionados: conservar el historial y avisar a los clientes cuando hay actividad nueva. Discord Engineering describe una migración de un historial de billones de mensajes que pasó de 177 nodos de Cassandra a 72 de ScyllaDB, según el reporte de 2023 [1]. Zulip también ofrece chat por canales y organiza conversaciones por temas para equipos que trabajan de forma sincrónica o en horarios distintos [2].

Pendiente: Añadir la razón personal para elegir Discord.

2. Arquitectura

La API HTTP permite solicitar el historial y crear mensajes. La arquitectura publicada por Discord ubica servicios de datos entre la API y los clústeres de ScyllaDB. Los servicios exponen operaciones gRPC y pueden reunir solicitudes simultáneas de una misma fila en una sola consulta. Discord también describe un enrutamiento por identificador de canal que ayuda a reunir solicitudes relacionadas en una instancia [1].

El Gateway entrega eventos por WebSocket. La ruta de entrega de eventos y la consulta del historial son operaciones distintas: una mantiene actualizado al cliente conectado y la otra obtiene mensajes que ya se guardaron. La API pública describe la reanudación de sesiones para aplicaciones, que usan un identificador de sesión y un número de secuencia [3].

Pendiente: Incorporar el diagrama digital elaborado por Byron y explicar cómo evolucionó desde su bosquejo.

3. Conceptos de sistemas distribuidos

3.1. Transparencias

Acceso. Desde el cliente se consulta un canal a través de la API. La interfaz oculta las operaciones del motor de almacenamiento.

Ubicación. El usuario trabaja con un identificador de canal. La API y el enrutamiento interno resuelven dónde atender la solicitud.

Migración. Durante el cambio de Cassandra a ScyllaDB, Discord escribió datos nuevos en ambos motores y contrastó una muestra de lecturas antes del cambio de base principal [1].

Reubicación. La documentación consultada permite analizar el traslado de datos durante la migración. El efecto de mover en caliente un servicio mientras procesa una solicitud queda sin verificar.

Replicación. El usuario ve un historial. La selección y coordinación de copias corresponde a la infraestructura, como se documenta para el clúster de autenticación [4].

Concurrencia. Solicitudes simultáneas de la misma fila pueden compartir una consulta al almacenamiento [1]. El orden observado en la prueba corresponde a un solo emisor.

Fallos. La interfaz puede mostrar la pérdida de conexión. En la prueba, la actualización del historial visible se recuperó automáticamente después de reconectar la laptop.

3.2. CAP y PACELC

Para CAP, interesa qué puede responder una operación si parte de las réplicas queda incomunicada. Discord describe lecturas por cuórum en el clúster de autenticación, con datos repartidos en tres zonas. Si una partición deja a un lado sin el cuórum requerido, una lectura en ese lado no puede completar con esa política. Durante el incidente documentado, el problema observado fue de disponibilidad de autenticación bajo mantenimiento y degradación de recursos [4]. El análisis de sistemas replicados de alta disponibilidad ayuda a identificar qué propiedades pueden debilitarse ante fallos [5].

La parte de PACELC que se aplica en operación normal pregunta cuánto cuesta coordinar réplicas frente a responder con menor latencia. En un sistema con lecturas por cuórum, esperar a varias réplicas introduce una dependencia de sus tiempos de respuesta. Las mediciones publicadas de configuraciones NoSQL muestran que el efecto de variar la consistencia depende del motor, la operación y el despliegue [6]. Discord reportó que el percentil 99 de lectura de historial pasó de 40–125 ms con Cassandra a 15 ms con ScyllaDB después de su migración y cambios de arquitectura [1]. Ese dato describe una mejora observada y no identifica por sí solo la política de consistencia del historial.

3.3. Modelos de comunicación

Discord sigue un modelo cliente-servidor. En HTTP, el cliente inicia la solicitud y recibe una respuesta. El Gateway usa un WebSocket persistente para entregar eventos asíncronos a aplicaciones conectadas [3]. En la ruta interna de almacenamiento, gRPC permite invocar operaciones remotas del servicio de datos [1]. La separación de eventos y solicitudes permite que distintas partes progresen a ritmos diferentes. En arquitecturas por eventos, esa separación obliga a especificar qué significa que dos componentes hayan sincronizado su estado [7].

3.4. Tolerancia a fallos

El informe de Discord sobre el 6 de noviembre de 2023 describe cómo el mantenimiento de una zona y un disco degradado en otra redujeron la capacidad del clúster de autenticación. Los reintentos añadieron carga y la interrupción afectó la lectura y el envío de mensajes [4]. Durante ese incidente, Discord observó tiempos de espera en las solicitudes de autenticación. La pérdida temporal de capacidad durante la actualización redujo el margen disponible ante el disco degradado. Tras la recuperación, el equipo amplió el clúster y revisó el proceso de actualización [4]. La replicación ayuda a tolerar la pérdida de una zona, pero la capacidad de las restantes también condiciona el servicio. Los reintentos pueden agravar la sobrecarga cuando muchas solicitudes fallan a la vez.

4. Experimento

4.1. Piloto asistido

El 12 de noviembre de 2026, Codex operó dos clientes web en una PC. Chrome recibió el mensaje de control `BYRON-PILOTO-M0`. El segundo mensaje, `BYRON-PILOTO-M1`, apareció en Chrome mientras DevTools aún mostraba `Offline`. El ajuste no aisló al receptor en esta ronda, por lo que el piloto no permite medir la recuperación tras un corte.

4.2. Prueba principal

En la primera ronda, Byron comprobó la recepción de un mensaje de control en Chrome. Durante el corte envió tres mensajes desde el celular. Una captura del navegador posterior al envío aún mostraba solo el mensaje de control de esta ronda. Al reconectar, los tres mensajes aparecieron sin recarga manual. La captura posterior muestra una entrada de cada mensaje, en orden M1, M2 y M3. La hora visible corresponde a la captura. El tiempo de recuperación quedó sin medir. La laptop usó Chrome y el teléfono permaneció conectado con datos móviles. Los comandos `Get-Date`, `whoami` y `Write-Output` registraron la hora, el usuario y las observaciones manuales. El procedimiento está en `resultados/EXPERIMENTO.md`. La transcripción original está en `resultados/sesion-20261112-233908.txt` e incluye una anotación posterior sobre la reconexión.

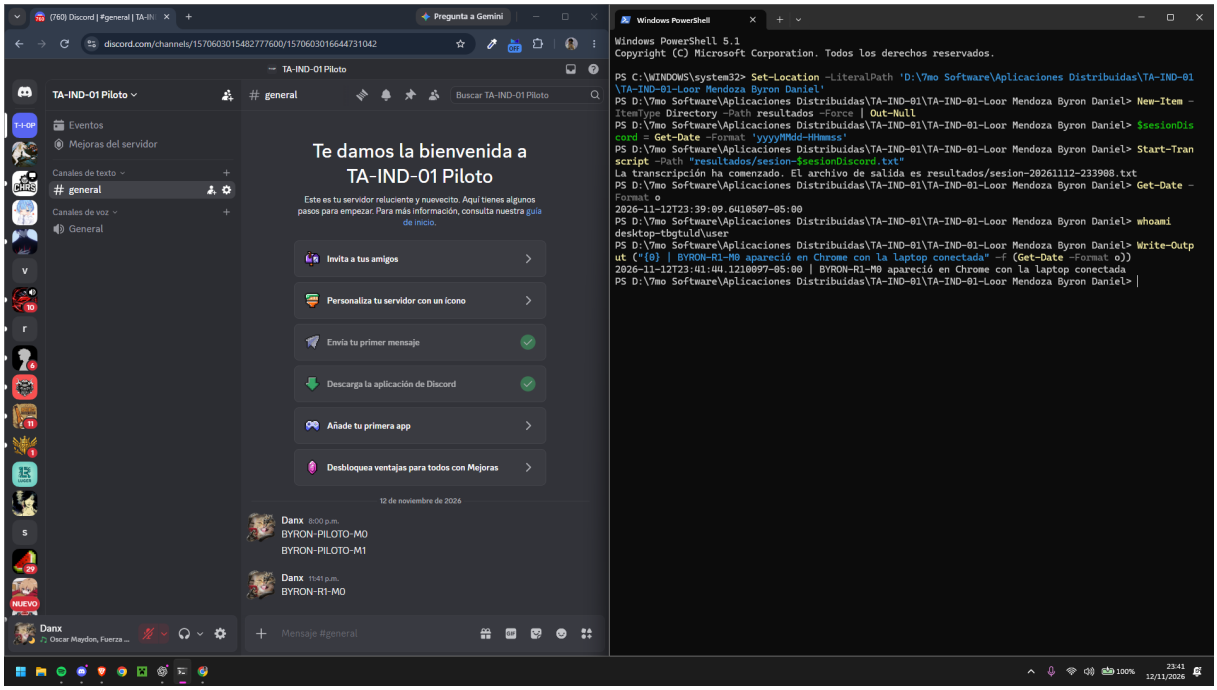


Figura 1: Mensaje de control visible en Chrome con la laptop conectada.

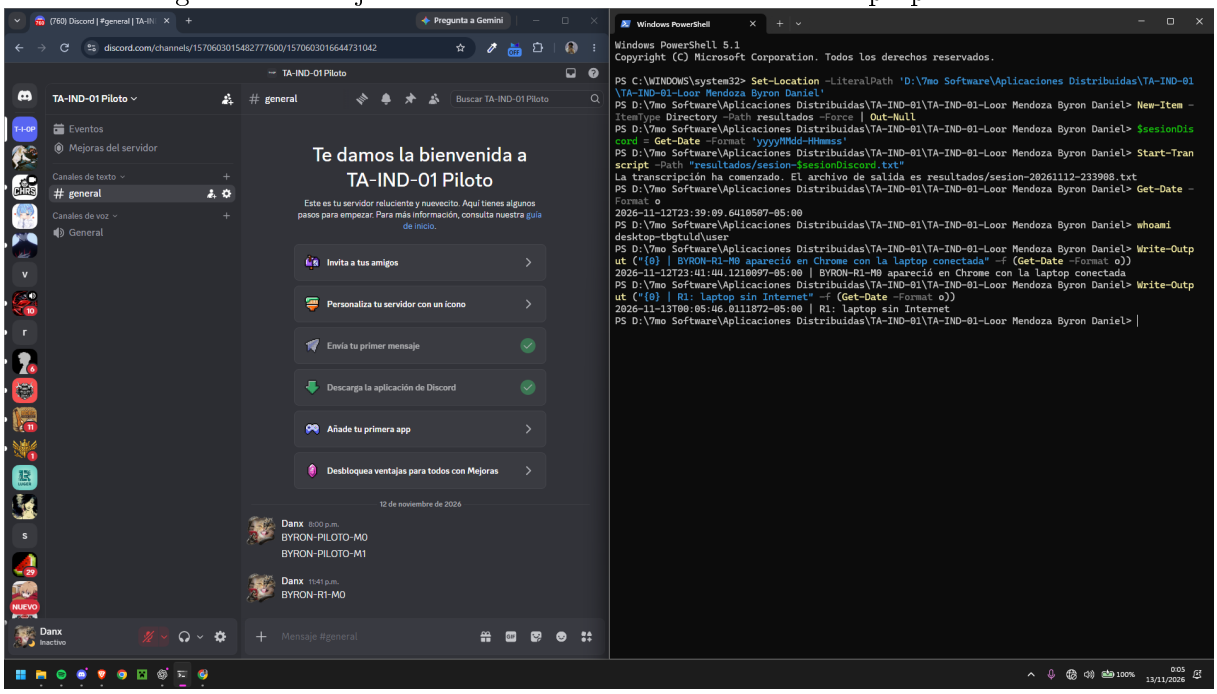


Figura 2: Inicio del corte con el indicador de red de Windows sin Internet.

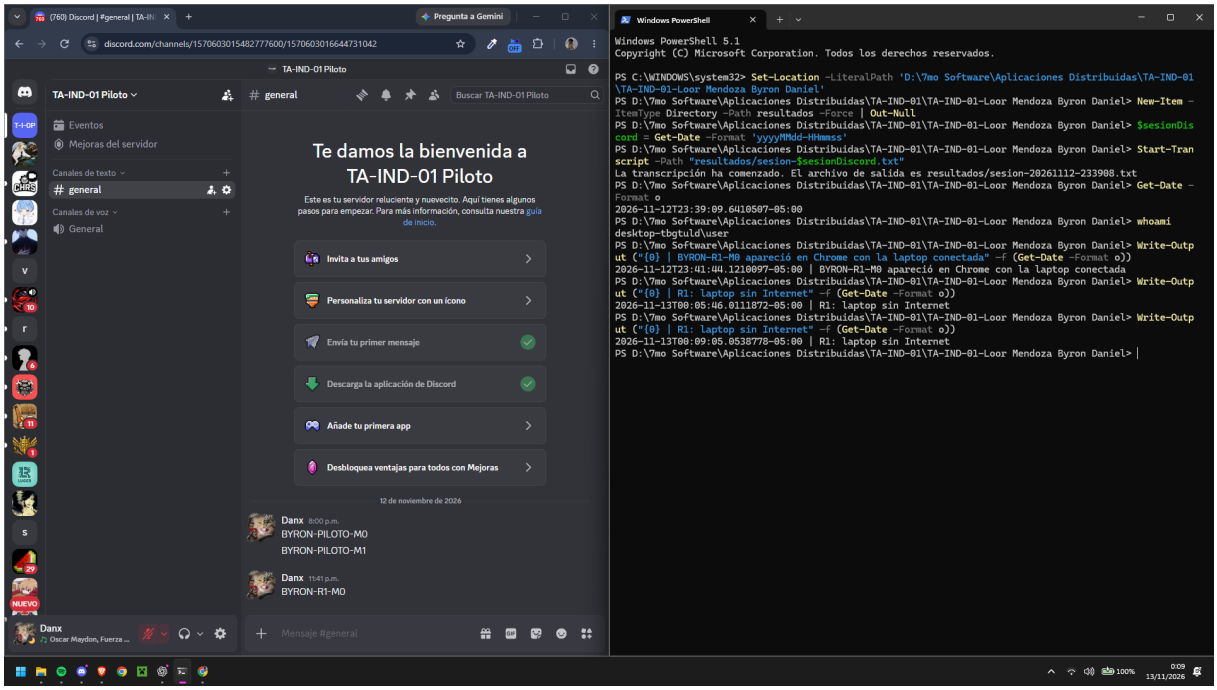


Figura 3: Chrome aún muestra M0 a las 00:09. El registro manual y el icono de Wi-Fi se conservan como aparecen en la captura.

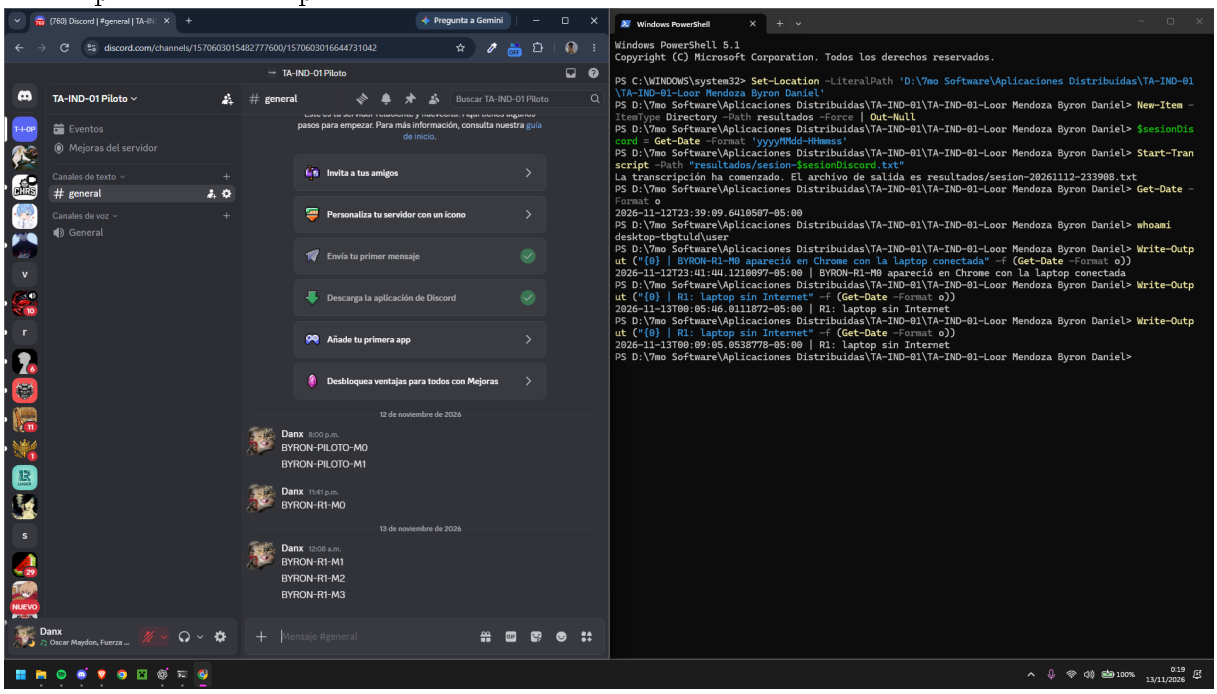


Figura 4: Estado capturado a las 00:19 con los tres mensajes visibles después de reconectar.

El resultado describe la recuperación del estado visible del cliente. La prueba interrumpió el acceso a la red de una laptop y mantuvo el teléfono conectado. Las réplicas del servicio quedaron fuera del control experimental. Por eso, la observación no permite clasificar Discord según CAP ni identificar si el cliente reanudó una sesión del Gateway o consultó el historial.

5. Ejemplos del entorno

Discord y el aviso de reconexión. Cuando se corta mi conexión, he visto el aviso «Reconectando» en la zona del micrófono de Discord. Cuando vuelve Internet, la aplicación cambia de estado. Esto ilustra una transparencia a fallos parcial: el cliente puede gestionar la reconexión y, al mismo tiempo, hacer visible la interrupción al usuario.

Zulip y el historial por temas. En la demo de Zulip, Byron envió `ZULIP-M1` al tema *Prueba TA-IND-01* del canal `#general`. Con apoyo de Codex se abrió el tema *saludos* y luego se volvió a *Prueba TA-IND-01*, donde el mensaje seguía visible. El ejemplo ilustra la transparencia de acceso: el usuario consulta el historial por canal y tema desde la interfaz, que se encarga de obtener los datos. La figura 5 muestra el resultado de la comprobación.

6. Comparación con Zulip

La comparación considera Discord como servicio administrado y Zulip como una instalación con servidor de aplicación y PostgreSQL separados, según la configuración documentada [1], [8], [9].

Criterio	**Discord**	**Zulip**
Arquitectura	API, servicios de datos y ScyllaDB para el historial.	Django atiende solicitudes y Tornado entrega eventos.
Comunicación	API HTTP y eventos del Gateway por WebSocket.	Solicitudes HTTP y espera prolongada mediante *long polling*.
Transparencia de acceso	El cliente consulta mensajes por canal mediante la API.	El usuario consulta canales y temas mediante la aplicación, que accede a la base.
Almacenamiento	Particiones de mensajes en el clúster documentado.	PostgreSQL guarda el mensaje y su relación con los destinatarios.
Consistencia y latencia	Lecturas por cuórum en el caso documentado de autenticación.	Escritura transaccional en el servidor primario. La configuración de replicación condiciona la recuperación.
Recuperación	La API Gateway documenta reanudar sesiones para aplicaciones.	El cliente confirma eventos mediante su último ID. Si la cola expira, obtiene el estado inicial de nuevo.

Fuentes de la comparación [1], [3], [4], [8], [9], [10], [11]. Zulip conserva los mensajes en PostgreSQL y usa una cola por cliente para entregar las novedades. El último identificador recibido permite solicitar eventos pendientes mientras la cola existe. Si se configura una réplica de respaldo de PostgreSQL, la recuperación frente a una caída del primario implica promoverla antes de aceptar escrituras [9], [11]. Son dos recuperaciones distintas: la del cliente que perdió sus eventos y la del almacenamiento que debe volver a servir escrituras.

La demo permitió observar la organización del historial por temas en Zulip. La prueba de Discord observó la recuperación del historial visible tras un corte de conexión. La comparación de los mecanismos internos se apoya en la documentación técnica de cada plataforma.

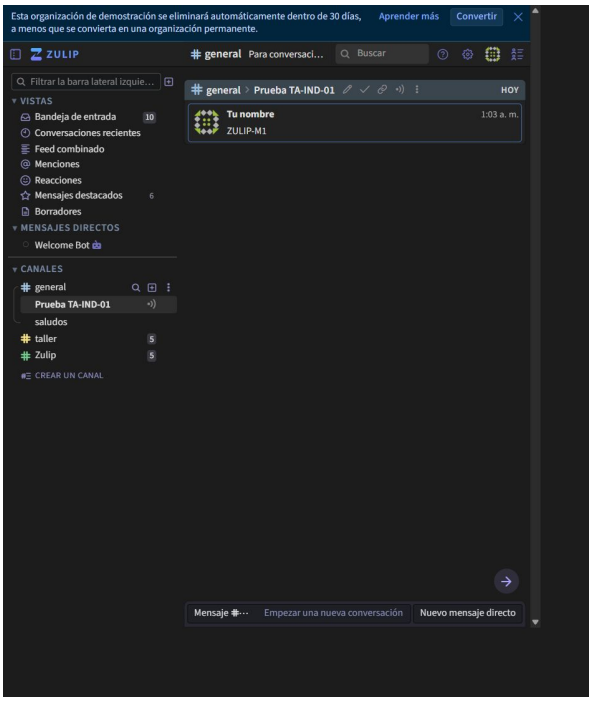


Figura 5: Mensaje enviado por Byron en el tema de prueba de Zulip. Codex capturó la vista al volver a abrir el tema.

7. Postura crítica

El diseño de Discord reduce la presión sobre el almacenamiento cuando muchos usuarios consultan los mismos mensajes. Reunir esas consultas protege a la base frente a ráfagas, aunque las particiones calientes siguen siendo un problema que el equipo debe vigilar [1]. Zulip puede ser preferible si el equipo necesita administrar el alojamiento y decidir cómo operar su PostgreSQL. Ese control añade trabajo de respaldo, supervisión y recuperación al equipo que lo aloja [2], [9].

En ambos casos conviene distinguir entre poder ver un mensaje tras reconectar y exigir una garantía para todas las operaciones ante un fallo. Una decisión que dependa de esa garantía requiere precisar la operación, la configuración de almacenamiento y las condiciones de fallo que debe soportar.

8. Conclusiones

En el ensayo de Discord, Chrome volvió a mostrar los tres mensajes enviados mientras la laptop estuvo desconectada, en el orden observado en el teléfono y sin recarga manual. Esto respalda la recuperación del cliente en la condición ensayada. La comparación explica por qué la entrega de eventos y la persistencia se evalúan por separado: los eventos mantienen actualizado al cliente y el historial proporciona una fuente que se puede consultar tras un corte.

Declaración de uso de inteligencia artificial

Se utilizó Codex (modelo GPT-6.1 Sol) para organizar y redactar partes del borrador, orientar la revisión de fuentes, asistir en el piloto y ordenar las capturas originales de la prueba que realizó el estudiante. En Zulip, Codex preparó el borrador del mensaje, verificó que siguiera visible al volver al tema y tomó la captura. Byron realizó el envío.

Pendiente: Completar la declaración con los usos posteriores y la verificación que realizó el estudiante.

Referencias

[1] B. Ingram. "How Discord Stores Trillions of Messages," Discord, visitado 12 de nov. de 2026. dirección: https://discord.com/blog/how-discord-stores-trillions-of-messages

[2] T. Abbott. "Zulip 12.0: Organized chat for distributed teams," Zulip, visitado 13 de nov. de 2026. dirección: https://blog.zulip.com/2026/04/27/zulip-12-0-released/

[3] Discord. "Gateway," visitado 12 de nov. de 2026. dirección: https://docs.discord.com/developers/events/gateway

[4] M. Smith. "25 % or 6 to 4: The 11/6/23 Authentication Outage," Discord, visitado 12 de nov. de 2026. dirección: https://discord.com/blog/authentication-outage

[5] M. Kokociński, T. Kobus y P. T. Wojciechowski, "On the correctness of highly available systems in the presence of failures," *Journal of Parallel and Distributed Computing*, vol. 180, oct. de 2023, **artno** 104707, doi: 10.1016/j.jpdc.2023.04.008. visitado 12 de nov. de 2026. dirección: https://www.sciencedirect.com/science/article/abs/pii/S0743731523000709

[6] S. Ferreira, J. Mendonça, B. Nogueira, W. Tiengo y E. Andrade, "Impacts of data consistency levels in cloud-based NoSQL for data-intensive applications," *Journal of Cloud Computing*, vol. 13, 2024, **artno** 158, doi: 10.1186/s13677-024-00716-7. visitado 12 de nov. de 2026. dirección: https://link.springer.com/article/10.1186/s13677-024-00716-7

[7] J. L. Bação y S. Guerreiro, "Consistency challenges in event-driven microservices: a literature review on data, process, and system evolution," *Computing*, vol. 108, 2026, **artno** 110, doi: 10.1007/s00607-026-01701-5. visitado 12 de nov. de 2026. dirección: https://link.springer.com/article/10.1007/s00607-026-01701-5

[8] Zulip. "Zulip architectural overview," visitado 12 de nov. de 2026. dirección: https://zulip.readthedocs.io/en/stable/overview/architecture-overview.html

[9] Zulip. "PostgreSQL database details," visitado 12 de nov. de 2026. dirección: https://zulip.readthedocs.io/en/stable/production/postgresql.html

[10] Zulip. "Sending messages," visitado 12 de nov. de 2026. dirección: https://zulip.readthedocs.io/en/stable/subsystems/sending-messages.html

[11] Zulip. "Real-time push and events," visitado 13 de nov. de 2026. dirección: https://zulip.readthedocs.io/en/stable/subsystems/events-system.html

A. Bosquejo inicial

Pendiente: Insertar la foto original del esquema a mano con nombre y fecha visibles.

B. Lectura de fuentes

Pendiente: Insertar tres capturas propias de los artículos con la página visible, la anotación personal y la cita correspondiente.